

Analyse Transactionnelle et Inférence Statistique

Science des Données,
A25: IFT-599/799

@Jordan Félicien Masakuna

Commenté [OC1]: @Jordan Félicien Masakuna

@Luc Nathan Ramasamy

Commenté [OC2]: @Luc Nathan Ramasamy

@Pathy Jane Noutcha Ngounou

Commenté [OC3]: @Pathy Jane Noutcha Ngounou

@Owen Couturier

Commenté [OC4]: @Owen Couturier

I. Préparation des données

a. Fusion de tous les fichiers du jeu de données

Dans ce projet, plusieurs jeux de données ont été fusionnés afin de construire un DataFrame enrichi et cohérent, prêt pour l'analyse. Tout d'abord, les identifiants ont été harmonisés : la colonne id du DataFrame des utilisateurs "df2" a été renommée en client_id pour permettre une jointure claire avec celui des cartes "df1". Une fusion interne (inner) a ensuite été réalisée entre df1 et df2 sur la clé client_id, garantissant que seules les correspondances exactes soient conservées. Après cette étape, la colonne id issue de df2 a été renommée en card_id afin d'éviter toute ambiguïté lors des fusions suivantes. Le DataFrame obtenu a été fusionné avec celui des transactions "df3", cette fois sur les clés combinées client_id et card_id, toujours en jointure interne, pour relier chaque transaction à son client et à sa carte.

Ensuite, le dictionnaire data2 contenant les descriptions MCC a été transformé en DataFrame (df_mcc) et les types de données ont été harmonisés en int pour permettre une fusion correcte. Une jointure gauche (left) a été utilisée pour enrichir les transactions avec les descriptions MCC, tout en conservant les lignes même si certaines n'avaient pas de correspondance. De manière similaire, les étiquettes de fraude issues du dictionnaire data1["target"] ont été converties en DataFrame (df_fraud) et les identifiants ont été convertis en chaînes de caractères pour assurer la compatibilité. Une dernière fusion gauche a été effectuée sur la colonne id, permettant d'ajouter le statut de fraude à chaque transaction.

b. Variables du jeu de données à exclure

Dans le but d'optimiser la pertinence analytique du jeu de données fusionné, plusieurs variables ont été supprimées car elles ne contribuent pas directement aux objectifs du projet. Les identifiants techniques tels que client_id, merchant_id ou id ont été retirés car ils sont principalement utilisés pour les jointures et n'apportent pas d'information comportementale utile à l'analyse. Les variables liées aux caractéristiques techniques des cartes (card_brand, expires, cvv, has_chip, use_chip, num_cards_issued, card_on_dark_web) ont été jugées redondantes ou peu informatives dans le cadre d'une analyse comportementale, d'autant plus que certaines sont fortement corrélées entre elles ou avec des variables déjà conservées. De même, les informations géographiques (merchant_city, merchant_state, latitude, longitude) ont été exclues en raison de leur granularité excessive ou de leur taux de valeurs manquantes, rendant leur exploitation difficile sans enrichissement externe.

Les données démographiques (`current_age`, `retirement_age`, `birth_year`, `birth_month`, `gender`) ont également été retirées, soit parce qu'elles sont redondantes (âge calculable à partir de l'année de naissance), soit parce qu'elles n'ont pas de lien explicite avec les comportements transactionnels ou les patterns de fraude observables dans les séquences. Enfin, des variables comme `acct_open_date`, `year_pin_last_changed`, `num_credit_cards` ont été exclues en raison de leur faible qualité (valeurs manquantes ou incohérentes), ou de leur faible pouvoir explicatif dans les modèles d'association ou de détection de fraude.

c. Opération de nettoyage pour la qualité des données

Dans le cadre du nettoyage du jeu de données, une opération d'imputation a été réalisée sur la variable `zip`, qui contenait des valeurs manquantes. Plutôt que de supprimer ces lignes, ce qui aurait pu réduire la représentativité du jeu de données, la moyenne (`zip_score`) a été calculée et utilisée pour remplir les valeurs manquantes. Cette approche permet de conserver l'intégralité des données tout en assurant une cohérence statistique minimale, bien qu'il soit important de noter que l'imputation par moyenne peut lisser des variations locales et doit être utilisée avec prudence si les données sont fortement corrélées à des comportements spécifiques.

d. Variables dérivées créées et ajoutées

Dans le cadre de l'enrichissement du jeu de données, plusieurs variables dérivées ont été générées pour capturer des dimensions temporelles, comportementales et financières plus fines. À partir de la date de transaction, les variables jour et heure ont été extraites pour identifier les habitudes d'achat selon le jour de la semaine et l'heure. Une variable delta a été calculée pour mesurer l'intervalle entre deux transactions successives par carte, ce qui permet d'analyser la fréquence et la régularité des usages. En complément, une variable période catégorise les heures en plages temporelles (matin, après-midi, soir, nuit), facilitant l'analyse des comportements selon les moments de la journée.

Sur le plan financier, le ratio dette/revenu (`debt_income_ratio`) a été construit après nettoyage des symboles monétaires, offrant une mesure de la pression financière potentielle du client. Le montant des transactions a été normalisé (`Montant_Normalisé`) pour faciliter les comparaisons, et catégorisé en quatre niveaux (`amount_category`) selon les quartiles, permettant une segmentation comportementale. D'autres variables ont été encodées pour faciliter l'analyse : `card_type_item` pour le type de carte, `credit_score_item` pour le niveau de crédit, et `merchant_type` pour le type de commerce, basé sur la description MCC.

Enfin, des indicateurs comportementaux ont été ajoutés, comme `card_usage_freq` qui mesure la fréquence d'utilisation de chaque carte, et `is_fraud`, une variable cible binaire indiquant si la transaction est frauduleuse ou non. La variable `mcc_category`, issue de la description MCC, permet également d'enrichir l'analyse sectorielle des transactions.

e. Conclusions et interprétations faites

L'analyse visuelle des commerçants les plus actifs révèle des dynamiques intéressantes selon deux axes : le volume de transactions et les revenus générés. Le premier diagramme en secteurs met en évidence que les commerçants les plus sollicités en nombre de transactions sont les supermarchés, les stations-service, les restaurants et les pharmacies. Cela reflète des comportements d'achat quotidiens et récurrents, souvent liés à des besoins essentiels ou à des déplacements. En revanche, le second diagramme, basé sur les revenus, montre que les transferts d'argent, les clubs de vente en gros et les services publics dominent en termes de chiffre d'affaires. Cela suggère que certaines catégories, bien que moins fréquentes, génèrent des montants plus élevés par transaction.

Par ailleurs, l'analyse des périodes de pointe montre une concentration marquée des transactions entre 8h et 12h, avec un pic notable en matinée. Ce comportement peut s'expliquer par des habitudes de consommation avant le travail ou durant les premières heures d'ouverture des commerces. L'activité diminue progressivement après 13h, avec une chute significative en fin d'après-midi et en soirée. Ces observations peuvent orienter des décisions stratégiques, comme l'optimisation des horaires de service, le ciblage marketing ou la surveillance renforcée des périodes à risque en matière de fraude.

f. Méthode d'encodage la plus adaptée

Dans le cadre de l'analyse des transactions et de la détection de fraude, l'encodage des variables catégorielles telles que les codes MCC ou les types de cartes est une étape cruciale pour rendre les données exploitables par des algorithmes d'apprentissage automatique. Pour les variables à faible cardinalité comme `card_type`, un encodage par one-hot encoding est souvent recommandé, car il permet de représenter chaque catégorie sous forme de vecteurs binaires sans introduire de hiérarchie artificielle. Cela évite que les modèles interprètent à tort une relation d'ordre entre les types de cartes. En revanche, pour des variables à forte cardinalité comme les codes MCC, qui peuvent contenir des dizaines voire des centaines de valeurs distinctes, le label

encoding peut être envisagé si l'on utilise des algorithmes insensibles à l'ordre des entiers (comme les arbres de décision). Toutefois, cette méthode peut introduire des biais si elle est appliquée à des modèles linéaires ou à des réseaux de neurones.

Une alternative plus robuste pour les variables à haute cardinalité est l'encodage par fréquence ou target encoding, qui consiste à remplacer chaque catégorie par une statistique agrégée (comme le taux de fraude moyen associé à chaque MCC). Cette approche permet de conserver une trace analytique des catégories tout en réduisant la dimensionnalité. Il est également judicieux de conserver les colonnes originales dans une version parallèle du jeu de données, notamment pour les visualisations ou les interprétations post-modèle. Enfin, il convient de documenter chaque transformation pour assurer la traçabilité et faciliter le suivi des variables tout au long du pipeline analytique.

II. Analyse d'associations

a. Transformation des données en données transactionnelles

Après avoir prétraité les données, il est temps de comparer les données obtenues à partir du prétraitement. Ce prétraitement a permis de créer des variables catégorielles nécessaires pour une analyse transactionnelle. Chaque transaction créée a des différences ou des similitudes entre eux et l'objectif de cette partie est de détecter les transactions qui ont des données récurrentes (similitudes).

b. Génération des règles d'association

Pour pouvoir détecter ceux-ci et ainsi de créer des règles d'associations (selon la récurrence d'une donnée dans les transactions), on applique, sur les transactions, les algorithmes d'Apriori et de FP-Growth. Pour résumer les deux méthodes, Apriori est un algorithme basé sur le fait que si une transaction est fréquente, tous les sous-ensembles de celui-ci sont fréquents. L'algorithme est idéal sur un échantillon de transactions, car celle-ci génère beaucoup de candidats potentiels. FP-Growth est un algorithme qui crée un arbre de fréquences compressant la base de données. Cela veut donc dire que l'arbre sera le plus détaillé lorsqu'on donne énormément de transactions donc un grand ensemble de données, mais c'est plus dur à implémenter que l'algorithme d'Apriori qui est plus simple et intuitif. Si on se fie à notre cas, on applique les deux algorithmes sur environ 2000 transactions (créés à partir des données prétraitées afin de trouver des récurrences chez les habitudes des clients). Le temps de calcul des deux algorithmes dépend de la quantité des transactions utilisés dans les algorithmes. Donc, utiliser plus de 10 000

transactions prendra plus de temps tandis que le nombre actuel de transactions prend environ 6 minutes. Ensuite, on extrait les 5 premières règles, puis on évalue le support et le lift de chaque règle.

c. Interprétation des résultats

À présent, on interprète les règles transactionnelles obtenues, tout en répondant aux questions spécifiques du travail (cela est possible en triant les règles obtenues, surtout en triant l'antécédant et la conséquence de chaque règle). Généralement, un lift supérieur à 1 ou au seuil minimal posé (dans notre cas, 1.2 et pas 1 afin de faire ressortir tous les cas particuliers) signifie que la corrélation entre les deux données est positive et qu'il y a donc un lien entre eux. L'opposé signifie que la corrélation est négative et qu'il n'y a donc aucun lien entre eux. Un lift égal au seuil minimal signifie que les données sont indépendantes entre eux. Pour le support, cela correspond au nombre de fois que la règle apparaît parmi les transactions. Dans notre cas, le support pour chaque règle doit être inférieur au support minimal imposé pour chaque algorithme, soit 0.2. Donc, les règles qui apparaissent le plus souvent sont très proche du support minimal tandis que ceux qui apparaissent le moins souvent s'éloignent le plus du support minimal. Pour montrer plus concrètement le résultat des valeurs obtenues par les métriques, un graphe orienté et un graphique de points montrent visuellement comment les règles d'association s'appliquent aux transactions créées avec les données prétraitées.

Commenté [OC5]: dépend de la machine, donc en général ce propos est intéressant quand mis en perspective avec du hardware, sinon on peut être plus pragmatique et dire "ça dure trop longtemps", mais ça va

Commenté [LR6R5]: Pas juste de la machine, l'algorithme est vraiment plus lent lorsqu'on a beaucoup de transactions comme expliqué en classe

Commenté [7R5]: Oui bien sûr mais je parle du temps chiffré, 10 minutes sans référentiel machine c'est pas pertinent

III. Analyse des séquences

a. Construction des séquences clients

Pour construire des séquences client, une solution est d'ordonner les transactions par horodatage avec l'attribut `date` qui traduira une évolution dans le temps. Chaque séquence serait constituée d'itemsets formés d'attributs catégoriels tels que `amount\_category` qui permettent de comparer les comportements plus facilement. Dans ce cas d'étude, l'itemset modèle sera composé de :

- `merchant\_type`
- `amount\_category`
- `periode`
- `Statut`

Par la suite, on se rend compte qu'un itemset avec autant de conditions peut être trop restrictif (support minimale de 1% peu représentatif pour obtenir 3 séquences typiques seulement). Il peut alors être intéressant de se focaliser sur `merchant\_type` et d'augmenter la taille de l'échantillon. Voici un exemple de séquence cliente, c'est-à-dire l'ensemble des items enregistrés dans des transactions, ordonnées dans l'ordre chronologique :

Séquence 3 (longueur=10):

```
tools,_parts,_  
supplies_manufacturing  
money_transfer  
miscellaneous_food_stores  
miscellaneous_home_furnishing_stores  
miscellaneous_food_stores  
...
```

b. Parcours typiques : PrefixSpan

Pour identifier des séquences typiques, il est possible d'utiliser des algorithmes comme SPADE ou PrefixSpan. Dans le cadre de cette étude, PrefixSpan a été utilisé dans son implémentation du module dédié "prefixspan" de chuancongao. Il faut définir un support minimal qui sert à filtrer les séquences insignifiantes, une longueur minimale et maximale de séquence. On obtient ainsi une liste de séquences avec leur support.

Comme précisé précédemment, utiliser un itemset de plusieurs critères diminue le support des séquences et la taille de l'échantillon déjà réduit pour des raisons de performances ne permet pas d'obtenir de résultats significatifs sur de tels croisements de critères. Ainsi, l'étude s'est bien portée sur `merchant\_type` dans un premier temps.

c. Parcours d'achats fréquents

Dans la continuité de l'application de PrefixSpan, il est intéressant d'analyser les résultats les plus fréquents. Dans le cadre de cette étude, seulement 35 résultats sont ressortis donc un tri descendant sur le support est suffisant pour tout visualiser, en voici un extrait :

support	motif
191	[miscellaneous_food_stores, miscellaneous_food_stores]
147	[service_stations, service_stations]
142	[grocery_stores,_supermarkets, grocery_stores,_supermarkets]
101	[eating_places_and_restaurants, grocery_stores,_supermarkets]
91	[grocery_stores,_supermarkets, eating_places_and_restaurants]
87	[miscellaneous_food_stores, miscellaneous_food_stores, miscellaneous_food_stores]

La séquence la plus fréquente présente un support de 191, elle est donc repérée chez 191 des 2000 clients soit environ **10%**. On remarque aussi que les items concernent principalement des catégories liées à **l'alimentaire ou la mobilité**, des besoins de première nécessité. D'autre part, la double séquence la plus fréquente sur `miscellaneous\_food\_stores` est aussi fréquente en triple. Ces motifs répétés sont les séquences qui semblent figurer parmi les plus fréquentes, ce qui permet d'**inférer que la distribution n'est pas uniforme et qu'il y a une dépendance temporelle entre les événements**.

d. Motifs précédant une fraude

Une application intéressante du minage de séquence serait la détection de fraude. S'il est possible de miner des séquences fréquentes précédant une fraude, il serait aussi possible d'inférer de manière informée les données manquantes (NaN) dans le jeu de données voire de prédire des fraudes.

Techniquement, la complexité augmente d'un niveau avec l'introduction d'itemsets pour associer un attribut à celui de fraude, par exemple il est possible de croiser `merchant\_type` avec `Statut`. Cependant, le minage de

De la même manière, la taille de l'échantillon ne permet pas de conclure sur les évolutions du comportement mais des itérations sur différentes périodes permettrait de l'étudier.

Pour visualiser des séquences, il est possible de représenter chaque item comme des nœuds d'un graphe dont les transitions sont orientées par les séquences et pondérées par leurs supports.

Il serait possible d'utiliser une version fermée de PrefixSpan pour n'obtenir que les séquences englobantes, ici le choix s'est plutôt orienté vers un découplage des

nœuds en fonction de la position de l'item dans la séquence. Cette approche permet de visualiser intuitivement les séquences comme des transitions mais aussi d'établir des liens entre les séquences.

IV. Système de recommandation

Que ce soit par l'analyse d'associations ou de séquences, miner des groupes d'items probables permet de faire des recommandations. Cette partie permet de synthétiser les travaux précédant sous la forme d'une fonction dans "recommandation.py".

Globalement, il y a la préparation des données pour l'application de PrefixSpan puis la récupération des séquences les plus fréquentes. Ensuite, le système de recommandation en soi consiste en un dictionnaire associant des complémentaires d'associations. Par exemple pour [miscellaneous_food_stores, miscellaneous_food_stores] on associera `miscellaneous\_food\_stores` à `miscellaneous\_food\_stores` :

Par défaut: ([grocery_stores,_supermarkets'], 834)

Séquence simple: ([miscellaneous_food_stores'], 191)

Deux items: ([miscellaneous_food_stores'], 87)

On note aussi que par défaut pour tout item ne faisant pas partie d'une règle de recommandation, l'item le plus probable est renvoyé avec sa fréquence.

V. Analyse statistique comparative des classes

a. Distribution des transactions (légitimes et frauduleuses) et réduction de dimension

Parmi les transactions obtenues du jeu de données, la distribution est la suivante : on a plus de transactions légitimes que frauduleuses et cela est démontré dans les techniques de réduction de dimension. De ce qu'on voit des représentations graphiques de chaque technique, on voit que l'affichage des transactions en 2D (2 dimensions ou 2 composantes), peu importe la technique, facilitent la visualisation des données (en 3D, on n'a rien puisqu'on évalue que x et y). Les visualisations montrent qu'on a deux regroupements (Classe 1 – transactions légitimes, classe 2 – transactions frauduleuses) et les anomalies correspondraient aux transactions légitimes qui sont trop loin du cluster de transactions légitimes.

b. Approche univariée

Avant d'utiliser l'approche univariée, définissons nos hypothèses afin de comparer les p-value obtenues de chaque méthode. L'hypothèse nulle est $H_0 \rightarrow \mu_{legitime} = \mu_{fraude}$ tandis que l'hypothèse alternative est $H_1 \rightarrow \mu_{legitime} \neq \mu_{fraude}$. Comparons les p-value de chaque méthode en considérant un $\alpha = 0.05$. Pour t-Test, consistant à comparer la différence entre deux moyennes, on a un p-value de 2.3644e-02 (0.023644) pour la variable de montant et un p-value de 1.2950e-02 (0.012950) pour la variable heure. Pour Mann-Whitney, consistant à comparer deux groupes distincts dans un échantillon, on a un p-value de 9.1768e-01 (0.91768) pour la variable de montant et un p-value de 2.7453e-02 (0.027453) pour la variable heure. Pour Kolmogorov-Smirnov, consistant à savoir si deux échantillons suivent une même loi, on a un p-value de 5.3257e-01 (0.53257) pour la variable de montant et un p-value de 2.5492e-02 (0.025492) pour la variable heure. En vérifiant que $p < \alpha$, on peut faire la conclusion suivante : pour la variable de montant, les résultats sont contradictoires (deux tests (t-Test et KS) considèrent qu'on rejette l'hypothèse nulle avec la variable tandis qu'un test (MW) ne rejette pas l'hypothèse nulle) tandis que la variable heure, les résultats sont clairs, c'est-à-dire qu'on rejette l'hypothèse nulle avec cette variable.

c. Approche multivariée

Pour l'approche multivariée, on choisit parmi deux tests possibles : le test de Hotelling ou le test de l'analyse discriminante linéaire ou LDA. On a décidé de faire la LDA mais à une dimension, puisqu'on a deux variables pertinentes. En observant la représentation graphique du LDA, on remarque que les deux classes se superposent, montrant une faible séparation des classes. Cependant, on peut tout de même dire qu'on possède deux classes mais, par manque de transactions frauduleuses, on ne peut pas séparer clairement les deux classes de transactions. Avec l'approche univariée et celle-ci, on peut dire que l'hypothèse nulle est rejetée (on prend donc l'hypothèse alternative) et que on possède deux classes non distinctes (les fraudes se cachent dans les transactions légitimes).