

TP4 - IFT603

Réseaux de neurones

Luc Nathan Ramasamy

12 décembre 2025

1 Partie I - Preuve mathématique

Puisqu'on cherche l'équation du gradient, nous avons besoin des dérivées partielles selon a_i . Commençons par l'équation $E(W)$:

$$E(W) = - \sum_{n=1}^N \sum_{k=1}^K y_{kn} \ln(g_i(x_n)) \quad (1)$$

$$\rightarrow \frac{\partial E(W)}{\partial a_i} = \frac{\partial}{\partial a_i} \left(- \sum_{n=1}^N \sum_{k=1}^K y_{kn} \ln(g_i(x_n)) \right) \quad (2)$$

$$= - \sum_{n=1}^N \sum_{k=1}^K y_{kn} \frac{\partial}{\partial a_i} (\ln(g_i(x_n))) \quad (3)$$

Puisque n et k sont indépendants ($n \neq k$), on peut donc écrire la formule suivante :

$$\frac{\partial E(W)}{\partial a_i} = - \sum_{k=1}^K y_{kn} \frac{1}{g_i(x_n)} \frac{\partial g_i(x_n)}{\partial a_i} \quad (4)$$

On a, à présent, besoin de $\frac{\partial g_i(x_n)}{\partial a_i}$, qu'on obtient en dérivant $g_i(x_n)$. Pour rappel, on définit $g_i(x_n)$ ainsi :

$$g_i(x_n) = \frac{e^{-a_i}}{\sum_j e^{-a_j}} \quad (5)$$

Avant de dériver, on pose $u_k = e^{-a_i}$ et $S = \sum_j e^{-a_j}$ puis on dérive partiellement selon a_i ,

$$\frac{\partial g_i(x_n)}{\partial a_i} = \frac{(\frac{\partial u_k}{\partial a_i})S - u_k(\frac{\partial S}{\partial a_i})}{S^2} \quad (6)$$

$$\rightarrow \frac{\partial u_k}{\partial a_i} = -u_k \delta_{ki} \quad (7)$$

$$\rightarrow \frac{\partial S}{\partial a_i} = -u_i \quad (8)$$

$$\rightarrow \frac{\partial g_i(x_n)}{\partial a_i} = \frac{(-u_k \delta_{ki})S - u_k(-u_i)}{S^2} \quad (9)$$

Avant de factoriser la forme finale de la dérivée partielle, petite explication de la dérivée des variables posées. Pour $\frac{\partial u_k}{\partial a_i}$, la dérivée de e^{-a_i} est $-e^{-a_i}$ donc $-u_k$, puisqu'on dérive x dans e^x . Pour ce qui est de δ_{ki} , il s'agit du symbole de Kronecker, qui prend une valeur de 0 si $k \neq i$ et de 1 si $k = i$, étant donnée que le terme u_k dépend de a_i que si $k = i$, mais cela n'arrive pas tout le temps. Pour $\frac{\partial S}{\partial a_i}$, si $j = i$, alors le terme dépend de a_i et on obtient $-u_i$.

$$\frac{\partial g_i(x_n)}{\partial a_i} = \frac{u_k}{S^2} (-\delta_{ki}S + u_i) \quad (10)$$

On peut voir $\frac{u_k}{S}$ comme étant $g_k(x_n)$ et $\frac{u_i}{S}$ comme étant $g_i(x_n)$. Cela nous amène donc à ce qui suit :

$$\frac{u_k}{S^2} = \frac{g_k(x_n)}{S} \quad (11)$$

$$\rightarrow -\delta_{ki}S = -S\delta_{ki} \quad (12)$$

$$\rightarrow u_i = Sg_i(x_n) \quad (13)$$

$$\rightarrow \frac{\partial g_i(x_n)}{\partial a_i} = \frac{g_k(x_n)}{S} (-S\delta_{ki} + Sg_i(x_n)) \quad (14)$$

$$= g_k(x_n)(-\delta_{ki} + g_i(x_n)) = g_k(x_n)(g_i(x_n) - \delta_{ki}) \quad (15)$$

Maintenant, on remplace dans l'équation (4) :

$$\frac{\partial E(W)}{\partial a_i} = - \sum_{k=1}^K y_{kn} \frac{1}{g_k(x_n)} (g_k(x_n)(g_i(x_n) - \delta_{ki})) \quad (16)$$

$$\rightarrow = - \sum_{k=1}^K y_{kn} (g_i(x_n) - \delta_{ki}) \quad (17)$$

$$= - \sum_{k=1}^K y_{kn} g_i(x_n) + \sum_{k=1}^K y_{kn} \delta_{ki} \quad (18)$$

$$= -g_i(x_n) + y_i \quad (19)$$

Si $\sum_{k=1}^K y_{kn} = 1$, donc que $n = k$ et que la distribution de y est normalisée (somme égale à 1), alors $\frac{\partial E(W)}{\partial a_i} = y_i - g_i(x_n)$, en sachant que g_i ne dépend pas de la variable k .